1. Методология исследования

1.1. Цель и объект анализа

Цель — сегментировать страны по структуре товарного обмена (экспорт + импорт) и выявить устойчивые группы с похожими профилями специализации.

Объект — 12 стран:

- из файла экспорта: Россия, Польша, Литва, Латвия, Германия, Казахстан, Украина, Нидерланды, Китай;
- из файла импорта дополнительно: Турция, Бразилия, Индия.

Предмет — относительные показатели по 23 товарным группам (10 по экспорту, 13 по импорту).

1.2. Подготовка данных

- Объединение таблиц.
- Обработка пропусков.
- Стандартизация.

Итоговая матрица: 12 объектов × 23 признака.

1.3. Алгоритмы кластеризации

1. K-Means

- Параметры: n_clusters=4, random_state=42, n_init=20.
- Минимизирует сумму квадратов расстояний до центоидов.
- Silhouette = 0.346.

2. DBSCAN

- Параметры: eps ≈ 5.23 (70-й перцентиль 3-го ближайшего соседа), min_samples=2.
- Не требует заранее задавать число кластеров, может выделять шум.
- Результат:
    - Кластер 0: Бразилия, Индия, Турция
    - Кластер 1: Германия, Казахстан, Литва, Нидерланды, Польша, Россия
    - Кластер 2: Латвия, Украина
    - Шум: Китай

Китай помечен как выброс — его профиль сильно отличается от остальных (очень высокие значения по мебели, лекарствам, IT-оборудованию). Это согласуется с тем, что в K-Means и Hierarchical он образует отдельный кластер из одной точки.

Вывод по алгоритмам:
K-Means выдает четыре кластера. DBSCAN подтверждает три «плотных» группы и выделяет Китай как аномалию. Для интерпретации профилей далее используется разбиение K-Means (k = 4).

1.4. Снижение размерности и визуализация

- PCA (2 компоненты): PC1 объясняет 31,6 % дисперсии, PC2 — 23,1 %, суммарно 54,6 %.
- Тепловая карта профилей (z-score + абсолютные значения).
- Диаграммы метода локтя и силуэта.

2. Интерпретация полученных кластеров

Кластер 0 — Китай (одиночный)

Состав: Китай.

Профиль:

- Очень высокий экспорт мебели (52) и лекарств (27).
- Высокий импорт вычислительных машин (28), аппаратуры связи (18), спец. машин (12).
- Низкие позиции по легковым авто, автокомпонентам, молочной продукции, соевому шроту.

Интерпретация:
Специализация на готовой промышленной продукции (мебель, фарма) и импорте высокотехнологичного оборудования. Профиль резко отличается от остальных стран, поэтому DBSCAN корректно пометил Китай как шум/выброс.

Кластер 1 — «Европейско-евразийское ядро»

Состав: Германия, Казахстан, Литва, Нидерланды, Польша, Россия.

Профиль:

- Выше среднего: импорт легковых авто (+4,8), экспорт молока и сыров, чёрных металлов, лесоматериалов.
- Умеренно развиты почти все направления — профиль диверсифицированный.
- Ниже среднего: соевый шрот, вычислительная техника.

Интерпретация:
Страны с относительно сбалансированной структурой торговли: есть и сырьё/продовольствие, и промышленные товары (авто, металлы). Это «ядро» выборки — наиболее однородная и крупная группа.

Кластер 2 — «Импортёры сырья и автокомпонентов»

Состав: Бразилия, Индия, Турция.

Профиль:

- Сильный импорт: соевый шрот (18,7), части для авто (17,3), лекарства, растительное масло.
- Почти все экспортные позиции = 0 (в данных экспорта этих стран нет).

Интерпретация:
Группа стран, для которых в выборке представлены в основном импортные потоки. Специализация на закупках сырья (соя), автокомпонентов и лекарств. Отсутствие экспортных данных усиливает «импортный» характер кластера.

Кластер 3 — «Экспортёры сырья и продовольствия»

Состав: Латвия, Украина.

Профиль:

- Высокий экспорт: чёрные металлы, лесоматериалы, сахар, молоко, сыры, плиты ДСП.
- Импорт по большинству позиций = 0 (в данных импорта этих стран нет или активность низкая).

Интерпретация:
Классические экспортёры сырья и продуктов АПК. Близки друг к другу по структуре вывоза и отличаются от «ядра» отсутствием выраженного импорта машиностроительной продукции.

3. Финальные выводы по блокам анализа

Страны сегментированы на 4 устойчивые группы. K-Means, иерархическая кластеризация и DBSCAN согласованно подтверждают это разбиение. Китай выделяется как особый случай (DBSCAN — шум). Полученные профили пригодны для сравнительного анализа торговой специализации и таргетирования подходов к партнёрам.

Для более подробного анализа нужны более объемные датасеты, т.к. результаты чувствительны к отдельным параметрам, но по условию задания использовались именно такие таблицы.